Rapport de qualification du prototype CreditRisk

Ndeye Khadidiatou LO

Après l'ensemble des tests, j'estime que le prototype peut passer en phase pilote avec la version 1.3.0 du modèle, à condition qu'il reste un outil d'aide à la décision et que l'agent de crédit garde la main. Les 209 tests de ma suite passent et la couverture du code atteint 98 %. J'ai quand même relevé 8 anomalies, dont 2 critiques, et l'une d'elles n'est toujours pas réglée : le modèle laisse passer 83 % des défauts sur les crédits de 24 mois et plus.

1. Contexte et système testé

Le système doit estimer le risque qu'un demandeur de crédit ne rembourse pas. Il reçoit cinq informations sur le demandeur, les contrôle, calcule quelques variables supplémentaires, puis le modèle renvoie une probabilité de défaut que l'API traduit en classe de risque pour l'agent.

J'ai découpé le code en quatre modules, comme le demandait le sujet :

Composant	Fichier	Ce qu'il fait
Validation	`app/validation.py`	Vérifie le type et les bornes de chaque champ, refuse les champs en trop, contrôle que l'ancienneté est cohérente avec l'âge
Prétraitement	`app/preprocessing.py`	Calcule le taux d'effort (mensualité divisée par le revenu) et le logarithme du revenu et du montant, soit 8 variables en tout
Modèle	`app/prediction.py`, dossier `models/`	Charge le modèle en vérifiant son empreinte SHA-256, contrôle les dimensions et la sortie
API	`app/main.py`	Expose `GET /health`, `POST /predict` et `GET /model-info`, avec un format d'erreur unique

Pour les données, j'ai choisi un jeu synthétique de 6 000 dossiers que je génère moi-même (graine 42, 28,1 % de défauts, 4 200 dossiers pour l'entraînement et 1 800 pour le test). Ce jeu me permet de tester le système, mais il ne dit rien de la performance qu'aurait un vrai modèle de crédit sur une vraie clientèle.

Pour pouvoir tester la non-régression, j'ai entraîné quatre versions du modèle :

Version	Algorithme	Pourquoi je l'ai créée
1.0.0	Régression logistique avec pondération des classes	Version de référence, celle qui tourne dans l'API
1.1.0	Gradient boosting (HistGradientBoosting)	Une évolution « normale » du modèle
1.2.0	Régression logistique sans pondération des classes	Simuler une erreur de code qui dégrade le modèle
1.3.0	Gradient boosting avec contraintes de monotonie	Corriger l'anomalie ANO-02 trouvée pendant les tests

L'API classe la probabilité en trois niveaux : faible en dessous de 0,30, modéré entre 0,30 et 0,60, élevé à partir de 0,60. Chaque réponse rappelle que la décision finale appartient à l'agent.

2. Stratégie de test et matrice de traçabilité

Je suis parti des 7 exigences du sujet et j'en ai ajouté 11. Elles sont couvertes par 212 cas de test, que j'ai rangés en six fichiers :

Niveau	Fichier	Nombre de cas	Techniques utilisées
Unitaire	`test_validation.py`	52	Classes d'équivalence, valeurs limites
Fonctionnel	`test_api.py`	40	Vérification du contrat HTTP
Intégration	`test_integration.py`	22	Espion sur le pipeline, pannes simulées avec monkeypatch
Robustesse	`test_robustness.py`	85	Entrées invalides et inhabituelles, fuzzing avec graine fixe, tests métamorphiques
Non-régression	`test_regression.py`	12	Comparaison à la version 1.0.0 avec des tolérances fixées à l'avance
Démonstration CI	`test_echec_volontaire.py`	1	Test qui échoue exprès quand on l'active

Pour prioriser, j'ai classé en P1 tout ce qui peut mener à une mauvaise décision de crédit, à une fuite d'information technique, à une panne non signalée ou à une régression qui passerait inaperçue. Le reste, qui touche au respect du contrat ou à la qualité sans conséquence directe sur la décision, est en P2. Les tests P1 bloquent les Pull Requests.

ID	Exigence	Résultat attendu	Risque	Priorité	Cas de test	Statut
EX01	Âge entier de 18 à 75 ans	Valeur hors limites rejetée (422)	Évaluer un mineur	P1	test_ex01, API03, API08, ROB04	Conforme
EX02	Revenu numérique, fini et positif	Erreur contrôlée 422	Texte converti sans prévenir	P1	test_ex02, API04, ROB02, ROB03	Conforme
EX03	Durée entière de 1 à 60 mois	12,5 et 12.0 rejetés	Mensualité faussée	P1	test_ex03, API06, ROB04	Conforme
EX04	Probabilité finie entre 0 et 1	Contrat respecté	Décision incohérente	P1	API01, INT11, ROB07, REG07	Conforme
EX05	Modèle indisponible signalé	503 sur les 3 endpoints	Réponses fausses	P1	API09, INT07	Conforme
EX06	Entrée incomplète rejetée	422 avec le champ manquant	Valeur imputée sans contrôle	P1	test_ex06, API02, ROB01, INT08	Conforme
EX07	Une nouvelle version ne dégrade pas les critères critiques	Rappel et F1 ne baissent pas de plus de 0,03, AUC de plus de 0,02	Défauts non détectés	P1	REG01 à REG09	Conforme avec 1.3.0

ID	Exigence	Résultat attendu	Risque	Priorité	Cas de test	Statut
EX08	Champs non prévus refusés	422 extra_forbidden	Variable sensible ajoutée en douce	P2	test_ex08, API07, ROB06	Conforme
EX09	Ancienneté cohérente avec l'âge	422 si elle dépasse l'âge moins 14 ans	Donnée fausse ou frauduleuse	P2	test_ex09, ROB04	Conforme
EX10	Montant entre 10 000 et 500 millions de FCFA	422 hors bornes	Montant absurde évalué	P1	API05, API08, ROB04	Conforme après ANO-03
EX11	Entrée inhabituelle signalée et renvoyée vers l'agent	200, alerte et décision manuelle	Décision prise sur une extrapolation	P1	test_ex11, ROB05	Conforme après ANO-04
EX12	Toutes les erreurs au même format	400, 404 et 405 au format du contrat	Erreur que le client ne sait pas lire	P2	API10, API13, ROB03, ROB06	Conforme après ANO-01
EX13	Métadonnées fidèles au modèle chargé	Version, variables et SHA-256 cohérents	Mauvaise version en service	P2	API12, API15, INT06, REG02, REG05	Conforme
EX14	Pas de trace technique, requêtes traçables	Message générique et X-Request-ID	Fuite d'information	P1	INT09 à INT12, API14	Conforme
EX15	Résultats reproductibles	Même entrée, même sortie	Résultat impossible à auditer	P1	ROB07, REG04, REG06, INT14	Conforme
EX16	Le risque évolue dans le bon sens	Monotonie avec une tolérance de 0,02	Bons profils refusés	P2	ROB08	Non conforme en 1.0.0 (ANO-02), conforme en 1.3.0
EX17	Temps de réponse adapté aux agences	P95 sous 200 ms avec 20 requêtes simultanées	Agents qui attendent	P2	benchmark, Locust	Conforme
EX18	Chaque Pull Request est vérifiée automatiquement	Ruff, Pytest et couverture d'au moins 90 %	Régression fusionnée	P2	tests.yml	Conforme en local

Les préconditions, les données d'entrée et les résultats attendus de chaque cas sont détaillés dans `docs/plan_de_test.md`.

3. Tests fonctionnels et d'intégration

Les 40 tests fonctionnels et les 22 tests d'intégration passent tous. Pour chaque réponse d'erreur, j'ai écrit une fonction `verifier_erreur_propre` qui vérifie la structure `{erreur, id_requete}` et qui cherche dans la réponse des mots comme `Traceback`, un chemin de fichier, `site-packages` ou un nom d'exception. Si l'un d'eux apparaît, le test échoue.

Scénarios imposés pour l'API

Scénario	Entrée	Code attendu	Contenu attendu	Résultat
Requête valide	35 ans, 250 000, 1 000 000, 12 mois, 4 ans	200	7 champs, probabilité entre 0 et 1	200, probabilité 0,354, risque modéré
Champ obligatoire absent	Chacun des 5 champs retiré à tour de rôle	422	DONNEES_INVALIDES, type missing	Conforme (5 cas)
Âge négatif	age = -5	422	Erreur sur age	Conforme
Revenu en texte	"250000", "deux cent mille", ""	422	float_type, pas de conversion	Conforme (3 cas)
Montant nul ou négatif	0, -1, -1 000 000	422	Erreur sur montant_credit	Conforme (3 cas)
Durée non entière	12.5, 12.0, "12"	422	int_type	Conforme (3 cas)
Champ en trop	sexe = "F"	422	extra_forbidden	Conforme
Valeurs très élevées	De 10^4 à 10^15	422, ou 200 si la valeur reste dans les bornes	less_than_equal, ou alerte hors domaine	Conforme (5 cas)
Modèle indisponible	Fichier du modèle absent	503	MODELE_INDISPONIBLE sur les 3 endpoints	Conforme (3 cas)
Requête mal formée	JSON coupé, liste, texte, null, corps vide	400 ou 422	REQUETE_MAL_FORMEE ou DONNEES_INVALIDES	Conforme (8 cas)

J'ai ajouté cinq scénarios pour `/health`, `/model-info`, les erreurs 404 et 405, le renvoi de l'en-tête `X-Request-ID` et la cohérence de la version entre les endpoints.

Tests de bout en bout

Pour le scénario principal, j'ai placé un espion sur la fonction de prétraitement. Avec une seule requête, je vérifie que les données arrivent validées et bien typées, que le vecteur contient 8 variables avec un taux d'effort de 0,333, que la probabilité renvoyée est la même que celle du modèle appelé directement (à 10^-6 près) et que l'empreinte SHA-256 affichée par `/model-info` correspond bien au fichier chargé. Un autre test s'assure que le prétraitement est le même à l'entraînement et dans l'API.

J'ai ensuite simulé des pannes pour voir comment l'API réagit :

Panne simulée	Réponse obtenue
Modèle absent, corrompu, empreinte modifiée, métadonnées absentes, objet sans predict_proba	503 MODELE_INDISPONIBLE
Variable perdue après la validation, erreur dans le prétraitement	422 PRETRAITEMENT_IMPOSSIBLE
Mauvaises dimensions (1 × 5, 1 × 9, 2 × 8, vecteur à plat)	500 ERREUR_PREDICTION
Exception dans le modèle, sortie NaN, infinie, 1,5 ou -0,2	500 ERREUR_PREDICTION

Panne simulée	Réponse obtenue
Bug inattendu dans la couche applicative	500 ERREUR_INTERNE avec un message générique

Dans les messages d'erreur que j'injecte, j'ai volontairement mis des faux secrets (« Traceback secret », un chemin `/home/...`, une clé « confidentielle »). Aucun ne ressort dans la réponse, et l'API répond normalement à la requête suivante.

4. Robustesse et anomalies

Au premier lancement, 12 des 85 tests de robustesse ont échoué. Après mes corrections, il n'y a plus d'échec. Deux anomalies du modèle 1.0.0 restent connues et je les suis avec des tests marqués `xfail` en mode strict, qui me préviendront le jour où elles seront corrigées. Les sorties avant et après correction sont dans `reports/preuves/`.

J'ai séparé deux cas. D'un côté, les entrées invalides, que l'API doit refuser : valeurs `null`, textes, booléens, listes, NaN, Infinity, 1e400, entiers de 5 000 chiffres, mauvais schéma, clés en double, valeurs juste au-dessus ou en dessous des bornes. De l'autre, les entrées valides mais inhabituelles, comme un demandeur de 75 ans, un revenu de 10 millions de FCFA ou un crédit sur 60 mois. Celles-là sont traitées, mais l'API ajoute une alerte et renvoie le dossier vers une analyse manuelle. J'ai complété avec un fuzzing sur 500 demandeurs tirés au hasard (graine fixe) et des tests métamorphiques qui vérifient que le risque varie dans le bon sens.

ID	Gravité	Trouvée par	Ce que j'ai observé	Correction	Statut
ANO-02	Critique	ROB08	Avec le modèle 1.0.0, le risque monte avec le revenu : 0,316 à 500 000 FCFA, 0,454 à 1,8 million et 0,99 à 10 millions (risque élevé)	Modèle 1.3.0 avec contraintes de monotonie, plus la correction ANO-04	Ouverte en 1.0.0, corrigée en 1.3.0
ANO-05	Critique (métier)	Analyse par segment	Taux de faux négatifs de 5,4 % sous 12 mois, 51,6 % entre 12 et 23 mois et 83,0 % à partir de 24 mois, pour 24,7 % au global	Seuil par segment, variables supplémentaires, avis du métier	Ouverte
ANO-01	Majeure	ROB03, ROB06	Les erreurs 400, 404 et 405 sortaient au format FastAPI par défaut, sans code ni identifiant	Gestionnaire d'erreurs HTTP qui applique le format du contrat	Corrigée
ANO-03	Majeure	ROB04	Un montant de 0,0001 FCFA était accepté, avec une probabilité de 0,96 et un risque élevé	Montant minimum de 10 000 FCFA	Corrigée
ANO-04	Majeure	ROB05	L'alerte hors domaine s'affichait mais la décision suggérée ne changeait pas	Décision analyse_manuelle_hors_domaine	Corrigée

ID	Gravité	Trouvée par	Ce que j'ai observé	Correction	Statut
ANO-06	Majeure	REG01	Version 1.2.0 : rappel de 0,607 contre 0,753, alors que le F1 augmentait	Version rejetée	Bloquée
ANO-07	Mineure	REG03	Version 1.1.0 : écart de probabilité de 0,212 sur le jeu de référence, au-delà de la tolérance de 0,15	À analyser avant toute mise en service	Bloquée
ANO-08	Mineure	ROB08	Version 1.0.0 : risque de 0,294 à 100 000 FCFA puis 0,283 à 300 000 FCFA	Écart sous la tolérance de 0,02	Acceptée

L'anomalie ANO-02 m'a le plus surpris. Aucune métrique globale ne la montrait, et pourtant un demandeur avec un bon revenu se serait retrouvé classé à risque élevé. Ce sont les tests métamorphiques qui l'ont fait apparaître. Le registre complet se trouve dans `reports/registre_anomalies.md`.

5. Non-régression

Sur les trois versions candidates, seule la 1.3.0 respecte toutes les tolérances. La 1.2.0 est bloquée à cause d'une baisse du rappel de 0,146, que je n'aurais pas vue en regardant seulement le F1, puisqu'il augmente.

Ma référence, c'est le modèle 1.0.0 avec ses métriques sur les 1 800 dossiers de test et les probabilités qu'il donne sur un jeu de 60 dossiers fixes que j'appelle le jeu « or ». J'ai écrit les tolérances dans `reference/tolerances.json` avant de lancer la moindre comparaison : le rappel et le F1 ne doivent pas baisser de plus de 0,03, l'AUC de plus de 0,02, la probabilité d'un dossier ne doit pas bouger de plus de 0,15, et au plus 20 % des dossiers peuvent changer de classe de risque.

Version	Rappel	Précision	F1	AUC	Écart de probabilité max	Changements de classe	Verdict
1.0.0 (référence)	0,753	0,644	0,694	0,884	0	0 %	Référence
1.1.0	0,741	0,637	0,685	0,876	0,212	17 %	Non conforme
1.2.0	0,607	0,832	0,702	0,884	0,231	15 %	Non conforme
1.3.0	0,749	0,629	0,684	0,879	0,144	12 %	Conforme

Les autres contrôles demandés passent avec les versions 1.0.0 et 1.3.0. Les tests fonctionnels et d'intégration repassent avec le modèle candidat (73 tests réussis avec la 1.3.0). Les 60 dossiers du jeu « or » donnent des réponses conformes au contrat. Après sauvegarde et rechargement, les probabilités sont exactement les mêmes. Si je réentraîne avec la même graine, j'obtiens la même empreinte SHA-256. Enfin, les métriques écrites dans les métadonnées correspondent à celles que je recalcule.

J'ai aussi ajouté un test qui vérifie que mon contrôle détecte bien la version dégradée 1.2.0. Comme ça, je teste aussi que les tests de non-régression font leur travail. Le rapport détaillé est dans

`reports/rapport_non_regression.md`.

6. Performance

L'objectif est atteint. Avec 20 requêtes simultanées, le P95 de `/predict` est de 40,6 ms alors que je visais 200 ms, avec 557 requêtes par seconde et aucune erreur.

J'ai fixé l'objectif avant de mesurer : P95 sous 200 ms avec 20 requêtes simultanées, au moins 50 requêtes par seconde et 0 % d'erreur. Je suis parti de l'hypothèse d'une cinquantaine d'agents, dont 40 % utilisent l'outil au même moment aux heures de pointe. Avec 200 ms côté serveur, le temps total reste sous la seconde même si le réseau de l'agence est lent.

Les mesures ont été faites sur une machine virtuelle Linux (Intel Xeon 2,30 GHz, 2 cœurs, 7 Go de RAM) avec Python 3.13.18, FastAPI 0.162.2 et scikit-learn 1.9.1. Le serveur uvicorn tournait avec un seul worker en local, sans TLS, et le client httpx était sur la même machine.

Mesure	P50	P95	P99
Inférence du modèle seul (3 000 appels)	0,15 ms	0,31 ms	0,47 ms
Validation, prétraitement et inférence	0,16 ms	0,22 ms	0,26 ms
API en séquentiel (500 requêtes)	1,98 ms	2,96 ms	6,05 ms

Requêtes simultanées	P95 (ms)	Débit (req/s)	Erreurs
1	2,9	452	0 %
5	14,8	476	0 %
10	21,9	620	0 %
20	40,6	557	0 %
50	136,5	482	0 %

Avec Locust, j'ai simulé 50 utilisateurs ajoutés progressivement pendant 30 secondes. J'ai obtenu 9 606 requêtes, environ 320 requêtes par seconde, aucun échec et un P95 de 19 ms sur `/predict`.

Le modèle lui-même prend moins d'une demi-milliseconde, le temps est surtout passé dans la partie HTTP. Le débit plafonne autour de 500 à 600 requêtes par seconde, puis la latence augmente parce que les requêtes attendent leur tour sur l'unique worker. Pour monter en charge, il suffirait d'ajouter des workers. Ces chiffres montrent que le code n'a pas de goulet d'étranglement, mais ils devront être refaits sur le vrai serveur.

7. Automatisation avec GitHub Actions

Le workflow `.github/workflows/tests.yml` se lance à chaque push sur `main`, à chaque Pull Request, et on peut aussi le déclencher à la main. Il contient trois jobs qui s'enchaînent, et si l'un échoue les suivants ne se lancent pas :

1. Qualité du code avec `ruff check` et `ruff format --check`.

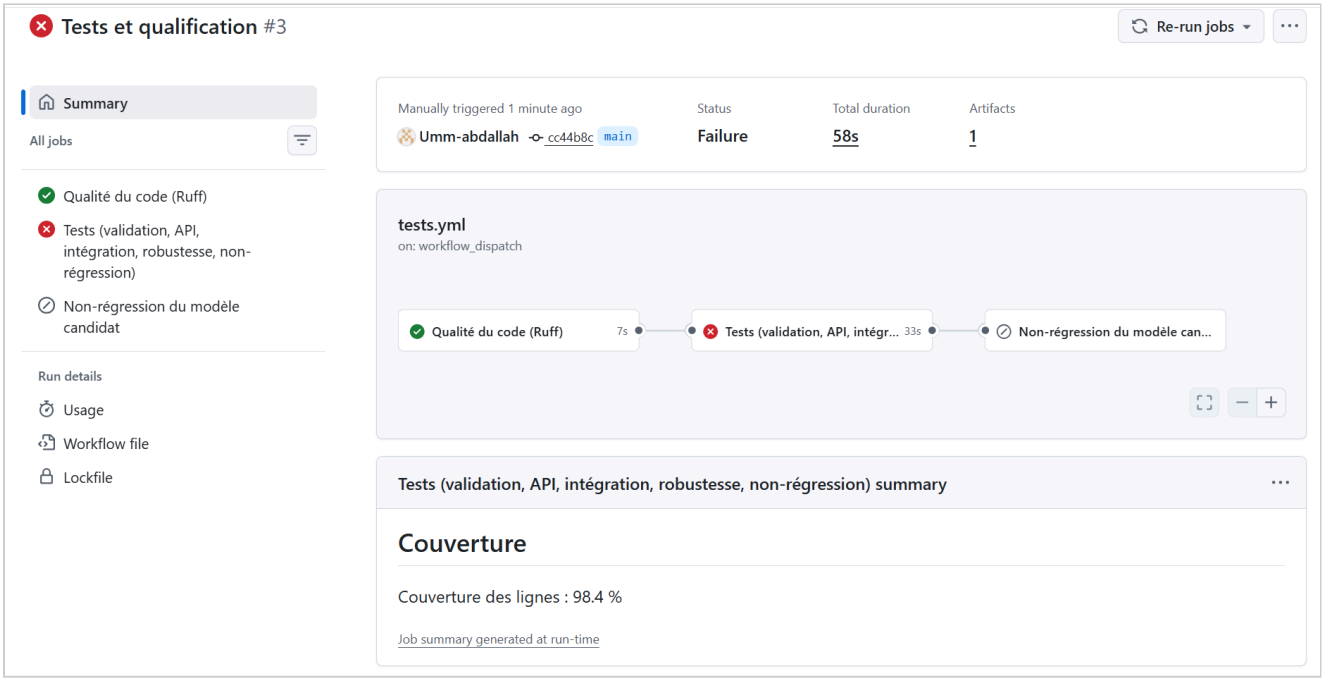
2. Tests : vérification de l'empreinte SHA-256 des modèles, puis la suite complète avec `pytest-cov` et un seuil de couverture de 90 %. Les rapports JUnit, XML et HTML sont publiés en artefacts.
3. Non-régression : le rapport comparatif des versions s'affiche dans le résumé du job, puis le modèle candidat (1.3.0 par défaut) passe le contrôle bloquant.

Pour que l'environnement soit reproductible, j'ai fixé Python 3.13 et toutes les versions des bibliothèques dans `requirements.txt` et `requirements-dev.txt`, et les modèles de test sont versionnés dans le dépôt. Le seul réentraînement fait en CI est celui du test de reproductibilité, une régression logistique qui prend moins de 2 secondes. La suite complète tourne en 6 secondes environ.

Pour montrer qu'un test qui échoue bloque bien le workflow, j'ai ajouté une option `forcer_echec` au déclenchement manuel. Elle active `test_echec_volontaire`, qui fait échouer le job de tests. En local, `FORCER_ECHEC=1 pytest` renvoie bien le code de sortie 1 (sortie dans `reports/preuves/echec_volontaire.txt`). Le modèle 1.2.0 fait lui aussi échouer le contrôle de non-régression.

En local, Ruff ne trouve aucune erreur, 209 tests passent, 1 est ignoré et 2 sont en `xfail`, avec 98 % de couverture en lignes et en branches. Le dépôt est en ligne à l'adresse https://github.com/Umm-abdallah/CreditRisk-Test. La première exécution du workflow sur GitHub est passée au vert sur les trois jobs (qualité, tests et non-régression).

J'ai ensuite lancé le workflow à la main avec l'option `forcer_echec`. Le job de tests a échoué sur `test_echec_volontaire` (1 échec et 209 tests réussis) et le job de non-régression ne s'est pas lancé. Le workflow bloque donc bien dès qu'un test échoue.



8. Limites, recommandations et conclusion

Limites

- Les données sont synthétiques. Les métriques obtenues (rappel de 0,753, AUC de 0,884) décrivent le générateur que j'ai écrit, pas une vraie clientèle.

- Je n'ai pas évalué l'équité ni la conformité légale. Je n'avais aucune variable protégée, et l'âge, que le modèle utilise, pourrait déjà poser un problème de discrimination.
- La sécurité est restée hors du périmètre : il n'y a ni authentification, ni limitation du nombre de requêtes, ni TLS.
- Les mesures de performance viennent d'une seule machine, sur laquelle le client et le serveur se partageaient 2 cœurs.
- Les seuils de 0,30, 0,50 et 0,60 n'ont pas été validés par la direction des risques.
- Mes tests vérifient le système à un instant donné. Ils ne suivent pas l'évolution de la clientèle dans le temps.

Recommandations

Priorité	Recommandation	Lien
1	Mettre en service le modèle 1.3.0, qui est monotone et qui passe la non-régression	ANO-02
1	Réduire les faux négatifs sur les crédits longs avec un seuil ou un modèle par tranche de durée, des variables en plus, et un rappel minimum par segment ajouté aux tests de non-régression	ANO-05
1	Réentraîner et requalifier le modèle sur des données historiques réelles, avec une validation dans le temps	Limites
2	Faire un audit d'équité (âge, genre, zone) et une revue juridique avant toute utilisation pour décider	Limites
2	Ajouter une authentification, une limitation du nombre de requêtes et TLS, et enregistrer chaque prédiction avec sa version	EX14
2	Surveiller en production la dérive des entrées, la part d'alertes hors domaine et les défauts réellement constatés	Limites
3	Refaire les mesures de performance sur le serveur cible avec plusieurs workers	EX17

Conclusion

Sur le plan technique, je donne un avis favorable. Avec la version 1.3.0, le système respecte ses 18 exigences : il rejette proprement les entrées invalides, signale ses pannes sans rien laisser fuiter, donne des résultats reproductibles, repère les régressions et répond bien plus vite que l'objectif.

Sur le plan métier, je ne recommande qu'un pilote encadré. Le modèle peut servir d'aide à la décision, mais c'est l'agent qui décide, et une analyse manuelle doit être obligatoire pour les crédits de 12 mois et plus ainsi que pour toute alerte hors domaine. Le modèle ne doit pas accorder ni refuser de crédit automatiquement tant que l'anomalie ANO-05 n'est pas corrigée et qu'il n'a pas été requalifié sur des données réelles.

9. Question de synthèse

Tous les tests fonctionnels et techniques passent, mais le modèle a encore un taux élevé de faux négatifs pour certains profils. Peut-on recommander sa mise en production ?

Pour moi, la réponse est non, en tout cas pas pour prendre des décisions. Et ce n'est pas une situation théorique dans mon projet : toute ma suite de tests est au vert, et le modèle rate pourtant 83 % des

défauts sur les crédits de 24 mois et plus.

Les tests techniques prouvent que le logiciel fait ce qu'on lui a demandé. Il valide les données, calcule, répond vite, signale ses pannes et donne toujours le même résultat pour la même entrée. Ils prouvent donc que le système est conforme à sa spécification, mais ils ne disent pas si les décisions qu'il suggère sont bonnes. Avec un rappel global de 0,753, le modèle paraît correct alors qu'il ne voit presque aucun défaut sur un segment entier.

Côté métier, un faux négatif veut dire qu'on accorde un crédit à quelqu'un qui ne remboursera pas. L'institution perd de l'argent, son portefeuille à risque se dégrade, et le client se retrouve surendetté. En plus, les crédits longs sont souvent ceux qui portent les plus gros montants, donc ce sont les pertes les plus lourdes. Ce qu'il faudrait exiger, c'est un rappel acceptable sur chaque segment, et pas seulement en moyenne. Ce critère ne figurait pas dans le cahier des charges, et c'est pour ça que les tests ne l'ont pas bloqué.

Les risques sont de plusieurs ordres. Il y a le risque financier, avec des pertes concentrées sur un segment, et le risque pour les clients, qui peuvent être poussés au surendettement alors qu'ils sont souvent vulnérables. Il y a aussi un risque d'équité : si les profils mal évalués correspondent à un groupe précis (les jeunes, les femmes, une zone rurale), l'erreur devient discriminatoire. Enfin, les agents risquent de faire trop confiance à un outil présenté comme « testé » et de relâcher leur vigilance.

Avant d'aller plus loin, je mettrais en place les contrôles suivants :

1. Ajouter aux exigences un rappel minimum par segment (durée, montant, âge, secteur d'activité, zone), défini avec la direction des risques, et en faire un critère bloquant de la non-régression.
2. Chercher la cause : variables manquantes, seuil unique mal adapté, trop peu de défauts sur crédits longs dans les données d'entraînement. Puis essayer un seuil par segment ou un modèle spécifique.
3. Requalifier le modèle sur des données réelles avec une validation dans le temps, puis faire un audit d'équité et une revue de conformité.
4. Pendant le pilote, imposer une analyse humaine sur les segments concernés, suivre les défauts réels et fixer à l'avance les critères qui feraient arrêter l'expérience.

Pour conclure, les tests me permettent de dire que le système fonctionne, pas que ses décisions sont bonnes. La mise en production reste une décision du métier, qui doit s'appuyer sur ces résultats techniques sans s'y limiter.